

Analyse du jeu de données CitiBike avec Hadoop MapReduce

Kaan Çolakoglu

7 décembre 2025

1 Introduction

L'objectif de ce devoir est d'analyser des données CitiBike à l'aide de jobs Hadoop MapReduce (Hadoop Streaming avec des scripts Python). Trois analyses principales ont été réalisées :

1. top 10 des stations les plus utilisées ;
2. comparaison des types d'utilisateurs (*Customer* vs *Subscriber*) ;
3. répartition horaire de l'activité.

2 Top 10 des stations

Le premier job compte le nombre de trajets par station de départ, puis trie les résultats pour obtenir les 10 stations les plus fréquemment utilisées.

```
Top 10 stations:
2025-12-07 21:32:53,471 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
"W 20 St & 11 Ave" 5983
"E 17 St & Broadway" 5621
"Broadway & W 58 St" 5401
"Broadway & E 14 St" 5177
"Broadway & W 24 St" 4955
"Central Park S & 6 Ave" 4925
"West Thames St" 4800
"West St & Chambers St" 4529
"Lafayette St & E 8 St" 4432
"8 Ave & W 31 St N" 4409
```

FIGURE 1 – Sortie console montrant le top 10 des stations les plus fréquemment utilisées.

On observe que plusieurs stations situées autour de Broadway et de Central Park apparaissent dans ce classement, ce qui est cohérent avec la forte densité d'activités (bureaux, commerces, tourisme) dans ces zones.

3 Types d'utilisateurs

Un autre job MapReduce agrège les trajets par type d'utilisateur et calcule le nombre de trajets ainsi que la durée moyenne.

```
Sample output (first 20 lines):
2025-12-07 21:33:21,412 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
"Customer" 240319 1753.23
"Subscriber" 337384 1101.42
```

FIGURE 2 – Sortie console pour la comparaison entre *Customer* et *Subscriber*.

Les *Subscribers* réalisent plus de trajets que les *Customers*, mais leurs durées moyennes sont plus courtes, ce qui suggère un usage régulier et utilitaire (trajets quotidiens) par rapport à un usage plus touristique ou de loisir pour les *Customers*.

4 Activité horaire

Le deuxième job comptabilise le nombre de trajets pour chaque heure de la journée (00h–23h). On peut ainsi identifier les heures de pointe.

```
Hourly activity (all 24 hours):
2025-12-07 21:33:49,361 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
00      7799
01     4359
02     2738
03     1605
04     1171
05     1931
06     7080
07    15966
08    32004
09    29130
10    23137
11    27249
12    34827
13    38151
14    38108
15    38166
16    41207
17    53334
18    53915
19    43077
20    31995
21    21731
22    16924
23    12099

--- Top 5 heures les plus actives ---
18h: 53915 trajets
17h: 53334 trajets
19h: 43077 trajets
16h: 41207 trajets
15h: 38166 trajets
```

FIGURE 3 – Nombre total de trajets par heure et top 5 des heures les plus actives.

Les heures les plus actives sont 18h, 17h, 19h, 16h et 15h, ce qui correspond clairement à la fin de journée de travail et aux déplacements domicile–travail.

5 Conclusion

Ces analyses montrent comment Hadoop MapReduce permet d’extraire rapidement des indicateurs utiles à partir d’un grand volume de données brutes : stations les plus fréquentées, heures de pointe et profils d’utilisation du service. Ces résultats peuvent aider à la planification urbaine et à l’optimisation du réseau de stations CitiBike.