

INF 438 – Bases de Données Avancées

Devoir 3 – AWS Free Data Lake

Dans ce devoir, vous allez créer un lac de données (data lake) simple entièrement gratuit en utilisant AWS Free Tier, et appliquer les étapes de collecte, transformation et analyse de données.

1. Préparation du Compte AWS

Avant de commencer le projet, chaque étudiant doit créer et configurer son propre compte AWS.

1.1. Création d'un Compte AWS

1. Accéder à : <https://aws.amazon.com>
2. Cliquer sur "Create an AWS Account"
3. Saisir les informations demandées (email, mot de passe, informations personnelles)
4. Sélectionner le type de compte : **Personal Account**
5. Vérifier l'adresse email
6. Procéder à l'activation du compte

1.2. Activation du Free Tier

1. Vérifier la section "Billing"
2. S'assurer que le niveau **AWS Free Tier** est actif
3. Activer les notifications de coûts (Billing → Budgets → Create Budget)

2. Aperçu du Projet

Services AWS Utilisés

- Amazon S3 - Stockage de données (5 GB gratuits)
- AWS Lambda - Transformation de données (1M requêtes/mois gratuites)
- Amazon CloudWatch - Surveillance (Métriques de base gratuites)
- S3 Select - Interrogation de données (inclus dans S3)

Avertissement sur les Coûts

Ce devoir est conçu pour être **ENTIÈREMENT GRATUIT**. Cependant :

- Faites attention à ne pas dépasser les limites du Free Tier
- Supprimez toutes les ressources après le devoir
- Coût estimé : 0 USD (dans les limites du Free Tier)

3. Partie 1 : Collecte et Stockage des Données

3.1. Création d'un Bucket S3

1. Aller dans AWS Console → S3
2. Créer un nouveau bucket :
 - Nom : nom-etudiant-data-lake
 - Région : eu-central-1 (Francfort)
 - Laissez "Block all public access" coché (sécurité)
 - Autres paramètres par défaut
3. Créer les dossiers suivants dans le bucket :
 - raw/
 - processed/

3.2. Création d'un Fichier de Données Exemple

1. Dans le TP on va utiliser le modèle des données suivants pour créer des données exemple

```
{
  "orderId": "{{random.number(1000)}}",
  "customerId": "{{random.number(100)}}",
  "productName": "{{commerce.productName}}",
  "price": {{commerce.price}},
  "orderDate": "{{date.now}}",
  "city": "{{address.city}}",
  "country": "{{address.country}}"
}
```

2. Utiliser le script Python ci-joint pour créer des données exemple

3.3. Téléchargement des Données vers S3

1. Ouvrez votre bucket dans la console S3
2. Entrez dans le dossier raw/
3. Cliquez sur le bouton "Upload"
4. Téléchargez le fichier orders_data.json
5. Terminez avec "Upload"

Vérification : Le fichier s3://nom-etudiant-data-lake-2024/raw/orders_data.json doit être visible

4. Partie 2 : Transformation de Données avec Lambda (ETL)

4.1. Création d'un Rôle d'Exécution Lambda

1. Console IAM → Roles → Create role
2. Trusted entity : AWS service → Lambda
3. Permissions :
 - AWSLambdaBasicExecutionRole (pour CloudWatch)
 - AmazonS3FullAccess
4. Nom du rôle: LambdaS3ETLRole

4.2. Création de la Fonction Lambda

1. Console AWS Lambda → "Create function"
2. Paramètres de la fonction :
3. Nom de la fonction : OrdersETLFunction
4. Runtime : Python 3.12
5. Rôle d'exécution : Use an existing role → LambdaS3ETLRole
6. "Create function"

4.3. Implémentation du Code de Transformation ETL

Dans cette étape, vous allez utiliser le script Python ci-joint pour réaliser le processus ETL dans l'éditeur Lambda qui lira automatiquement les données brutes de S3, les transformera (conversion en majuscules, calcul du prix total, ajout d'horodatage) et écrira les données traitées dans le dossier processed/.

IMPORTANT : Ne pas oublier de/d'

1. remplacer la variable `source_bucket` dans le code par le nom de votre propre bucket !
2. enregistrer le code en cliquant sur le bouton "Deploy"
3. faire la configuration → General configuration → Timeout : définir à 1 minute

4.4 : Test de la Fonction Lambda

1. Allez dans l'onglet "Test"
2. Nom de l'événement : TestEvent
3. JSON de l'événement : {} (vous pouvez le laisser vide)
4. Appuyez sur le bouton "Test"
5. Vous devriez voir un message de succès dans les résultats d'exécution
6. Vérifiez que le fichier `processed/orders_processed.json` a été créé dans S3

5. Partie 3 : Interrogation de Données avec S3 Select

S3 Select vous permet d'interroger directement les fichiers dans S3 avec des requêtes de type SQL.

5.1 : Première Requête avec S3 Select

1. Trouvez le fichier `processed/orders_processed.json` dans la console S3
2. Sélectionnez le fichier → Actions → "Query with S3 Select"
3. Paramètres d'entrée :
 - a. Format : JSON
 - b. Type de contenu JSON : JSON Lines (chaque ligne est un JSON séparé)
4. Paramètres de sortie :
 - a. Format : JSON

5.2 : Exemples de Requêtes

Note : Le fichier `orders_processed.json` a une structure JSON imbriquée (statistics + orders). Pour l'interroger avec S3 Select, on doit d'abord aplatir le fichier. Modifiez la dernière partie du code Lambda comme suit :

```
processed_lines = '\n'.join([json.dumps(order, ensure_ascii=False) for order in
processed_orders])

s3.put_object(
    Bucket=source_bucket,
    Key='processed/orders_lines.json', # Nom de fichier différent
    Body=processed_lines,
    ContentType='application/json'
)
```

Exécutez à nouveau Lambda. Maintenant le fichier `orders_lines.json` est dans un format interrogeable.

Exécuter les Requêtes SQL suivantes :

1. Afficher toutes les commandes
2. Nombre total de commandes
3. Répartition des commandes par ville
4. Chiffre d'affaires par pays
5. Produits les plus vendus

6. Analyses et visualisation des données

Développez un script Python qui effectue les tâches suivantes :

1. Connexion et Extraction :
 - Établissez une connexion avec le service S3 en utilisant boto3
 - Téléchargez le fichier de données depuis le bucket S3
 - Chargez les données JSON dans une structure de données appropriée
2. Préparation des Données :
 - Convertir les données en DataFrame pandas
 - Assurer que les types de données sont corrects (totalPrice en float, quantity en int)
3. Analyses Statistiques - Calculez et affichez les analyses suivantes :
 - Résumé statistique général des données (moyenne, médiane, min, max, etc.)
 - Ventes totales par ville (agrégation et tri décroissant)
 - Top 5 des produits les plus vendus (comptage par produit)
 - Distribution des statuts de commande (comptage par statut)
 - Ventes totales par pays (agrégation par pays)
4. Visualisation Graphique -- Créez un dashboard composé de 4 graphiques :
 - Graphique en barres : Top 10 des villes par volume de ventes
 - Graphique en barres : 5 produits les plus vendus
 - Graphique circulaire : Distribution des statuts de commande (avec pourcentages)
 - Graphique en barres : Ventes par pays
 - Enregistrez le dashboard dans un fichier image nommé sales_analysis.png

7. Livrables

Télécharger sur moodle.gsu.edu.tr les fichiers suivants dans un ZIP nommé avec votre numéro

7.1. Captures d'Écran

- Structure du bucket S3 (dossiers raw, processed, results)
- Vue du fichier raw/orders_data.json dans S3
- Code de la fonction Lambda (déploiement réussi)
- Résultat du test d'exécution Lambda (logs CloudWatch)
- Contenu du fichier processed/orders_processed.json (premières 10-20 lignes)
- Les requêtes exécutées avec S3 Select et leurs résultats

7.2. Rapport (1–2 pages)

Structure recommandée :

1. Introduction
2. Étapes réalisées
3. Problèmes rencontrés
4. Conclusion – Avantages de l'architecture Data Lake

7.3. Fichiers de Code

- generate_data.py (script de génération de données)
- lambda_function.py (code ETL Lambda)
- s3_select_queries.txt (requêtes SQL exécutées)